

Uso De Um Modelo De Regressão Linear Múltipla Para Prever A Dose De Radiação Em Circuitos Integrados

Samir Alves

[Repositório Do Modelo](#)

1 Introdução

O estudo publicado pela revista *Electronic Packaging and Production* (2002, Vol. 42) teve como objetivo analisar a dose de radiação (rads) produzida durante uma inspeção de circuitos integrados por raio X. No presente estudo foi identificado que a dose da radiação aumenta fortemente tanto com o tempo de exposição quanto com a corrente.

Nesse contexto, este trabalho teve como objetivo desenvolver um modelo de regressão linear múltipla para prever a dose de radiação tendo o tempo de exposição e a corrente utilizada durante a inspeção como variáveis explicativas.

2 Fundamentação Teórica

2.1 Definição De Um Modelo De Regressão Linear Simples

A regressão linear simples é um modelo estatístico que utiliza uma única variável independente para prever a variável dependente. Esse modelo encontra uma linha que, com a maior precisão possível, prevê os valores entre as variáveis dependentes e independentes.




Figura 1: Exemplo De Regressão Linear Simples

2.1.1 Modelo Matemático

A regressão linear simples pode ser representada pelo seguinte modelo matemático:

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i$$

Os coeficientes são calculados por:

$$\beta_0 = \bar{Y} - \beta_1 \bar{X}$$

$$\beta_1 = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sum_{i=1}^n (X_i - \bar{X})^2}$$

$$\varepsilon_i = Y_i - \hat{Y}_i$$

Onde:

Y_i — **Valor Observado**: representa o valor observado da variável dependente para a i -ésima observação.

β_0 — **Intercepto**: representa o valor esperado de Y_i quando $X_i = 0$.

β_1 — **Coeficiente Angular**: indica a variação esperada em Y para cada unidade de variação em X_i .

X_i — **Variável Independente**: representa o valor da variável independente para a i -ésima observação.

ε_i — **Resíduo**: representa a diferença entre o valor observado e o valor que seria explicado pelo modelo de regressão.

2.2 Exemplo

Suponha que será analisado a se o numero de horas de estudo (**X**) influencia o resultado de uma prova (**Y**). Após a análise de dados o seguinte modelo é encontrado. Supondo que o valor de $\beta_0 = 4$ e $\beta_1 = 1,5$:

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i \rightarrow Y_i = 4 + 1,5X_i + \varepsilon_i$$

Se o numero horas de estudo fossem 4. É substituído $X = 4$ no modelo matemático:

$$Y_i = 4 + 1,5(4)$$

$$Y_i = 10$$

Ou seja o modelo ira prever que nota com 4 horas de estudo será 10. Nesse contexto, suponha-se que um aluno tenha estudado 4 horas, mas sua nota real tinha sido 6.0.

O dado previsto foi:

$$Y_i = 10$$

Mas o dado real é:

$$Y = 6.0$$

Então o resíduo é:

$$\varepsilon_i = 6.0 - 10$$

$$\varepsilon_i = -4$$

Ou seja, o modelo errou por 4 unidades.




Figura 2: Exemplo De Uma Regressão Linear Múltipla Com Duas Variáveis Independentes

2.3 Definição De Um Modelo De Regressão Linear Múltipla

Um modelo de regressão linear múltipla utiliza duas ou mais variáveis independentes para prever uma variável dependente. O modelo estima uma relação linear que existe entre as variáveis, determinando os coeficientes que melhor representam essa relação e permitindo realizar previsões da variável dependente a partir dos valores das variáveis independentes.

2.3.1 Modelo Matemático

A regressão linear múltipla pode ser representada pelo seguinte modelo matemático:

$$Y_i = \beta_0 + \beta_1 X_{i,1} + \beta_2 X_{i,2} \dots + \beta_k X_{i,k} + \varepsilon_i$$

Os coeficientes são calculados por:

$$\beta_k = (X^T X)^{-1} X^T y$$

Onde:

β_0 — **Intercepto**: representa o valor esperado de Y quando $X_{i,k} = 0$.

β_k — **Coefficiente Angular**: representa o coeficiente angular da reta de regressão, indicando a variação esperada em Y_i para cada unidade de variação em $X_{i,k}$

$X_{i,k}$ — **Variável independente**: representa o valor da variável independente para a i, k -ésima observação.

ε_i — **Resíduo**: representa a diferença entre o valor observado e o valor que seria explicado pelo modelo de regressão.

2.4 Exemplo

Suponha que será analisado a se o área da casa em m^2 (X_1) e quantidade de cômodos (X_2) influencia o preço de uma casa (Y). Após a análise de dados o seguinte modelo é encontrado. Supondo que o valores de $\beta_0 = 50$, $\beta_1 = 4$ e $\beta_2 = 20$.

$$Y_i = \beta_0 + \beta_1 X_{i,1} + \beta_2 X_{i,2} \dots + \beta_k X_{i,k} + \varepsilon_i \rightarrow 50 + 4X_{i,1} + 20X_{i,2} + \varepsilon_i$$

Se $X_1 = 100$ e $X_2 = 3$ então:

$$Y_i = 50 + 4(100) + 20(3)$$

$$Y_i = 510$$

Ou seja o modelo irá prever que o valor da casa com 100m² e 3 cômodos será de 510 unidades. Nesse contexto, suponha-se que o valor real dessa casa fosse 780 unidades.

O dado previsto foi:

$$Y_i = 510$$

Mas o dado real é:

$$Y_i = 780$$

Então o resíduo será:

$$\varepsilon_i = 780 - 510$$

$$\varepsilon_i = 270$$

Conclui-se que o modelo errou a previsão de uma casa com 100m² e 3 cômodos por 270 unidades.

2.5 Métricas

Foram utilizadas as seguintes métricas para avaliar o modelo de regressão múltipla.

2.5.1 R^2

O coeficiente de determinação representa a proporção da variação da variável dependente que é prevista pelo modelo a partir das variáveis independentes. Essa métrica fornece uma medida de quão bem os resultados observados são replicados pelo modelo. Quanto mais próximo de 1.0 melhor o modelo

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

Onde:

y_i — Valor observado

$\hat{y}_i$ — Valor previsto pelo modelo

$\bar{y}$ — Média dos valores observados

n — Quantidade de observações

2.5.2 R^2_{adj}

O coeficiente de determinação ajustado é uma versão modificada do coeficiente de determinação que penaliza a adição de variáveis independentes que não contribuem na previsão da variável dependente. Quanto mais próximo de 1.0 melhor o modelo

$$R^2_{\text{adj}} = 1 - (1 - R^2) \frac{n - 1}{n - p - 1}$$

Onde:

R^2 — Coeficiente de determinação

n — Quantidade de observações

p — Quantidade de variáveis independentes

2.5.3 RMSE

A Raiz do Erro Quadrático Médio, ou Root Mean Square Error, é uma métrica utilizada para medir a distância entre os valores observados e valores previstos. Quanto mais próximo de 0.0 melhor o modelo

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

Onde:

y_i — Valor observado

$\hat{y}_i$ — Valor previsto pelo modelo

n — Quantidade de observações

2.5.4 MSE

O Erro Quadrático Médio, ou Mean Squared Error, é uma métrica utilizada para medir a média quadrática da diferença entre o valores preditos e valores observados. Quanto mais próximo de 0.0 melhor o modelo

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

Onde:

y_i — Valor observado

$\hat{y}_i$ — Valor previsto pelo modelo

n — Quantidade de observações

2.5.5 MAE

O Erro Médio Absoluto, ou Mean Absolute Error, é uma métrica utilizada para medir o erro médio absoluto entre os valores observados e valores preditos. Quanto mais próximo de 0.0 melhor o modelo

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

Onde:

y_i — Valor observado

$\hat{y}_i$ — Valor previsto pelo modelo

n — Quantidade de observações

3 Protocolo Experimental

O set de dados feito pelo estudo realizado pela revista *Electronic Packaging and Production* (2002, Vol. 42) contem 540 instâncias contendo as seguintes variáveis independentes *Tempo de Exposição* e *mAmp* e a variável dependente *Dose de Radiação*. Para realizar o processamento de dados foram utilizadas as bibliotecas *NumPy*, *Plotly* e *Matplotlib* na linguagem de programação *Python*. A implementação do modelo de regressão linear múltipla foi feita sem o uso de bibliotecas que já possuem o modelo implementado. Para a realização deste trabalho foram utilizadas três versões do modelo de regressão: Sem intercepto, Apenas uma variável independente e o modelo base. A versão com o $\beta_0 = 0$ foi considerada como possível modelo viável para a resolução do problema pois caso a corrente e tempo de exposição forem igual a 0 pode-se concluir que o valor da dose de radiação recebida, também, será igual a 0.

4 Resultados

4.1 Modelo Com Intercepto

O modelo com intercepto obteve os seguintes resultados:




Figura 3: Gráfico Do Plano De Regressão Do Modelo Com Intercepto




Figura 4: Gráfico do Valor Real x Predito Do Modelo Com Intercepto

Métrica	Valor
R^2	0.8431
R^2 ajustado	0.8425
RMSE	233.5167
MAE	187.5942
MSE	54530.0719

Tabela 1: Métricas de avaliação do modelo com intercepto

Usando R^2 , R^2_{adj} , $RMSE$ e MAE como as principais métricas de avaliação, o modelo apresenta uma capacidade de explicar 84,31% da variabilidade dos dados, como evidenciados nos gráficos do plano de regressão e do real x predito. Além disso, o modelo possui uma magnitude de erro de 233,5167 unidades entre os valores observados e previstos e uma diferença médias entre eles de 187,5942 unidades e um R^2_{adj} próximo do valor do R^2 indicando que as variáveis independentes não estão inflando o valor do R^2 .

4.1.1 Gráfico De Resíduos




Figura 5: Gráfico De Resíduos Do Modelo Com Intercepto

Como observado no gráfico os resíduos seguem um padrão de funil, significando que há indícios de heterocedasticidade, que é quando a variância do erro não permanece constante ao longo dos valores preditos. Nesse contexto, pode-se concluir que a uma limitação no modelo para representar de forma uniforme da variabilidade dos dados.

4.1.2 Coeficientes Estimados

Os seguintes coeficientes foram obtidos:

$$\beta_0 = -433,8144$$

$$\beta_1 = 17,9035$$

$$\beta_2 = 69,5790$$

Com os resultados obtidos pode-se concluir que quando a corrente aumenta em 1 *mAmp* a dose de radiação ira aumentar em 17,9035*rad*s e quando o tempo de exposição aumentar em 1*Min* a dose de radiação ira aumentar em 69,5790*rad*s. Além disso, quando todas as variáveis independentes forem igual a 0 a dose de radiação será de -433,8144*rad*s.

4.2 Modelo Sem Intercepto

O modelo sem intercepto obteve os seguintes resultados:

Grafico Do Plano De Regressão (Radiação - Sem Intercepto)




Figura 6: Gráfico Do Plano De Regressão Sem Intercepto




Figura 7: Gráfico do Valor Real x Predito Do Modelo Sem Intercepto

Métrica	Valor
R^2	0.7631
R^2 ajustado	0.7622
RMSE	286.9186
MAE	205.1239
MSE	82322.2571

Tabela 2: Métricas de avaliação do modelo sem intercepto

Usando R^2 , R^2_{adj} , $RMSE$ e MAE como as principais métricas de avaliação, o modelo apresenta uma capacidade de explicar 76,31% da variabilidade dos dados, como evidenciados nos gráficos do plano de regressão e do real x predito. Além disso, o modelo possui uma distância de erro de 286,9186 unidades entre os valores observados e previstos e uma diferença médias entre eles de 205,1239 unidades e um R^2_{adj} próximo do valor do R^2 , indicando que as variáveis independentes não estão inflando o valor do R^2 .

4.2.1 Gráfico De Resíduos




Figura 8: Gráfico De Resíduos Do Modelo Sem Intercepto

Como observado no gráfico os resíduos, também, seguem um padrão de funil, significando que há indícios de heterocedasticidade, que é quando a variância do erro não permanece constante ao longo dos valores preditos. Nesse contexto, pode-se concluir que a uma limitação no modelo para representar de forma uniforme da variabilidade dos dados.

4.2.2 Coeficientes Estimados

Os seguintes coeficientes foram obtidos:

$$\beta_0 = 0$$

$$\beta_1 = 4,8780$$

$$\beta_2 = 60,7470$$

Com os resultados obtidos pode-se concluir que quando a corrente aumenta em 1 *mAmp* a dose de radiação ira aumentar em 4,8780*rad*s e quando o tempo de exposição aumentar em 1*Min* a dose de radiação ira aumentar em 60,7470*rad*s. Além disso, nessa versão com o $\beta_0 = 0$ quando todas as variáveis independentes forem iguais a 0 o valor predito, também, será igual a 0.

4.3 Modelo Com Apenas Uma Variável Independente

O modelo com apenas uma variável independente, sendo a *Corrente*, obteve os seguintes resultados:




Figura 9: Gráfico Do Plano De Regressão Do Modelo Com Apenas Uma Variável Independente




Figura 10: Gráfico Do Valor Real x Predito Com Apenas Uma Variável Independente

Métrica	Valor
R^2	0.0807
R^2 ajustado	0.0790
RMSE	565.2392
MAE	464.2573
MSE	319495.3285

Tabela 3: Métricas de avaliação do modelo apenas uma variável independente

Usando R^2 , R^2_{adj} , $RMSE$ e MAE como as principais métricas de avaliação, o modelo apresenta uma capacidade de explicar 8,07% da variabilidade dos dados, como evidenciado no gráfico do plano de regressão. Além disso, o modelo possui uma magnitude de erro de 565,2392 unidades entre os valores observados e previstos e uma diferença médias entre eles de 464,2573 unidades e um R^2_{adj} próximo do valor do R^2 , indicando que as variáveis independentes não estão inflando o valor do R^2 .

4.3.1 Gráfico De Resíduos




Figura 11: Gráfico De Resíduos Do Modelo Com Apenas Uma Variável Independente

Como observado no gráfico os resíduos, também, seguem um padrão de funil, significando que há indícios de heterocedasticidade, que é quando a variância do erro não permanece constante ao longo dos valores preditos. Nesse contexto, pode-se concluir que a uma limitação no modelo para representar de forma uniforme da variabilidade dos dados.

4.3.2 Coeficientes Estimados

Os seguintes coeficientes foram obtidos:

$$\beta_0 = 91,1744$$

$$\beta_1 = 15,2475$$

Com os resultados obtidos pode-se concluir que quando a corrente aumenta em 1 *mAmp* a dose de radiação irá aumentar em 15,2475*rads*. Além disso, quando a *Corrente* for igual a 0 a dose de radiação será de 91,1744*rads*.

5 Discussão

Com base nos resultados obtidos o melhor modelo dentre os três utilizados foi o modelo base, com intercepto e com mais de uma variável independente, pois foi o que obteve melhor R^2 indicando que 84,31% da variabilidade da dose de radiação é explicada pela *Corrente* e *Tempo De Exposição*, e menores *RMSE* e *MAE*.

Porém, como observado no gráfico de dispersão o modelo apresenta a presença de heterocedasticidade, indicando que a variância dos erros não é constante ao longo dos valores preditos.

6 Conclusão

Com a realização desse trabalho conclui-se que a utilização de um modelo de regressão linear múltipla para prever a dose de radiação em um na inspeção de circuito integrado mostrou-se uma abordagem adequada para apresentar a relação entre *Corrente* e *Tempo De Exposição* com a *Dose de Radiação*. Os resultados obtidos demonstram que tanto a *Corrente* e o *Tempo De Exposição* apresentam uma relação positiva, como observada no valor dos coeficientes angulares dos três modelos, sobre a *Dose de Radiação* prevista pelo modelo.

A análise dos gráficos também permitiu avaliar o ajuste do modelo e o comportamento dos resíduos, sendo identificado a presença de heterocedasticidade nos resíduos. Dessa forma, o modelo apresenta potencial para auxiliar na estimativa da dose de radiação durante o processo de inspeção dos circuitos.